

Probabilidad y Estadística

Clase 2

Algunos comportamientos límite

LGN + TCL

Ley (débil) de los grandes números

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$$

$$E[\bar{X}_n] \stackrel{\text{lineal}}{=} \frac{1}{n} \sum_{i=1}^n E[X_i] = \mu$$


$$Var[\bar{X}_n] = Var\left(\frac{1}{n} \sum_{i=1}^n X_i\right) \stackrel{\text{indep}}{=} \frac{1}{n^2} \sum_{i=1}^n Var(X_i) = \frac{1}{n^2} \cdot n \cdot \sigma^2 = \frac{\sigma^2}{n}$$

Sea $\underline{X} = (X_1, \dots, X_n)$ una muestra aleatoria, con X_i i.i.d. con media μ y varianza σ^2 . Para $\epsilon > 0$ se tiene que

converge
en probabilidad

$$\mathbb{P}(|\bar{X}_n - \mu| > \epsilon) \xrightarrow{n \rightarrow \infty} 0$$

Es decir, a medida que crece la cantidad de muestras, el promedio $\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$ tiende a la media real de la distribución.



Teorema central del límite

convergencia en distribución

Sea $\underline{X} = (X_1, \dots, X_n)$ una muestra aleatoria, con X_i i.i.d. con media μ y varianza $\sigma^2 < \infty$. Sea $\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$, luego

estandarización

$$Z_n = \frac{\bar{X}_n - \mu}{\sqrt{\text{Var}(\bar{X}_n)}} = \frac{\sqrt{n}(\bar{X}_n - \mu)}{\sigma} \rightsquigarrow Z \quad \text{Normal estandar}$$

con $\underline{Z} \sim \mathcal{N}(0,1)$, o equivalentemente:

$\rightarrow \lim_{n \rightarrow \infty} \mathbb{P}(Z_n \leq z) = \Phi(z) = \int_{-\infty}^z \frac{1}{\sqrt{2\pi}} e^{-x^2/2} dx$ *Normal estandar*

Es decir, \bar{X}_n tiene una distribución aproximadamente Normal, con media μ y variancia σ^2/n . Para n finito, podemos aproximar

$$\mathbb{P}\left(\frac{\sum_{i=1}^n X_i - n\mu}{\sqrt{n}\sigma} \leq z\right) \approx \Phi(z), \quad \mathbb{P}\left(\sqrt{n} \frac{\bar{X}_n - \mu}{\sigma} \leq z\right) \approx \Phi(z),$$

Variables aleatorias condicionadas


Motivación

Cuando tenemos diferentes variables, que se encuentran vinculadas, saber qué ocurrió con una variable nos da información extra sobre las otras.

Las variables condicionadas aparecen en el corazón de ML,

- Modelos de regresión lineal/logística
- Modelos de árboles
- Modelos de grafos, que se basan en probabilidades condicionales
- Estimación paramétrica (enfoque Bayesiano)
- NLP: por ejemplo análisis de sentimientos basado en frecuencia de aparición de palabras en un texto.

Recordemos




Probabilidad condicional:

$$\underbrace{\mathbb{P}(A \mid B)}_{\substack{\text{"}\Omega\text{"} \\ \downarrow}} = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)} \leftarrow \text{Normalizar}$$

$\mathbb{P}(\cdot | B)$ es una probabilidad

$$\mathbb{P}(B|B) = 1$$

Variables discretas



Sean X, Y dos v.a.d.

$p_{X,Y}(x, y)$: func. de probabilidad conjunta

$p_X(x)$: func. de probabilidad marginal de X

Función de probabilidad condicional de Y dado $X = x$

func.
de prob.
de $Y|X$

$$p_{Y|X=x}(y) = \mathbb{P}(Y = y \mid X = x)$$

$$= \frac{\mathbb{P}(Y=y, X=x)}{\mathbb{P}(X=x)}$$

$$= \frac{p_{X,Y}(x, y)}{p_X(x)}$$

func. = $p_Y(y)$

Qué pasa si X, Y son independientes?

$$p_{X,Y}(x, y) = p_X(x) \cdot p_Y(y)$$

Variables Continuas

Sean X, Y dos v.a.c.

$f_{X,Y}(X,Y)$: func. de densidad conjunta

$f_X(X)$: func. de densidad marginal de X

$$F_X(x) = P(X \leq x)$$

$$P(Y \leq y | X \leq x) = \frac{P(Y \leq y, X \leq x)}{P(X \leq x)}$$

correlate las
densidades condicionales

Función de densidad condicional de Y dado $X = x$

$$f_{Y|X=x}(y) = \frac{f_{X,Y}(x,y)}{f_X(x)}$$

Qué pasa si X, Y son
independientes?

$$f_{X,Y}(x,y) = f_X(x) f_Y(y)$$

Factorización

Sean X, Y dos v.a.c.

$f_{X,Y}(x, y)$: func. de densidad conjunta

$f_X(x)$: func. de densidad marginal de X

$f_Y(y)$: func. de densidad marginal de Y

$$\begin{aligned} f_{X,Y}(x, y) &= f_{Y|X=x}(y) f_X(x) \\ &= f_{X|Y=y}(x) f_Y(y) \end{aligned}$$

Obs: si X, Y son independientes, $f_{X,Y}(x, y) = f_X(x) f_Y(y)$

Ejercicio 1



La probabilidad de acertar a un blanco es $\frac{1}{5}$. Se realizan 10 tiros independientes y se cuenta la cantidad de aciertos. Sean X la cantidad de aciertos en los 10 tiros, e Y la cantidad de aciertos en el primer tiro. Hallar la distribución de $X|Y=y$.

$$\begin{aligned} X: \text{"\# de aciertos en 10 tiros"} &\rightarrow X \sim \text{Bin}(10, 1/5) \\ Y: \text{"1er tiro"} &\rightarrow Y \sim \text{Ber}(1/5) \end{aligned}$$

$$\begin{aligned} \text{Si } x=0 &\Rightarrow P(Y=1)=0 \\ \text{Si } x=10 &\Rightarrow P(Y=1)=1 \end{aligned} \quad \left. \vphantom{\begin{aligned} \text{Si } x=0 &\Rightarrow P(Y=1)=0 \\ \text{Si } x=10 &\Rightarrow P(Y=1)=1 \end{aligned}} \right\} \text{No son indep.}$$

$$X = \sum_{i=1}^{10} Y_i \quad \text{con } Y_i \sim \text{Ber}(1/5) \text{ iid.}$$

$$X = Y + \sum_{i=2}^{10} Y_i = Y + W \quad \text{con } W \sim \text{Bin}(9, 1/5) \Rightarrow X|Y=y = y + W \quad \text{con } W \sim \text{Bin}(9, 1/5)$$

¿y cuál es la distrib. de $Y|X=x$?

con $Y_i, Y_i \sim \text{Ber}(1/5)$

si $x=0 \Rightarrow P(Y=0)=1$
 si $x=10 \Rightarrow P(Y=1)=1$. } No son indep.

$$X = Y + \sum_{i=2}^{10} Y_i$$

$W \sim \text{Bin}(9, 1/5)$

$$P(Y=1|X=1) = \frac{P(Y=1, X=1)}{P(X=1)} = \frac{\frac{1}{5} \cdot (\frac{4}{5})^9}{\binom{10}{1} \frac{1}{5} (\frac{4}{5})^9} = \frac{1}{10}$$

$$P(Y=1|X=2) = \frac{P(Y=1, X=2)}{P(X=2)} = \frac{115 \cdot P(W=1)}{\binom{10}{2} (\frac{1}{5})^2 (\frac{4}{5})^8} = \frac{\cancel{115}^2 \binom{4}{1} \cancel{(\frac{4}{5})^8}}{\binom{10}{2} \cancel{(\frac{1}{5})^2} \cancel{(\frac{4}{5})^8}} = \frac{\frac{9!}{1!8!}}{\frac{10!}{2!8!} = 10 \cdot \frac{9!}{8!}} = \frac{2}{10}$$

→ $P(Y=1|X=x) = \dots$ complete $\dots = \frac{x}{10}$

$Y|X=x \sim \text{Ber}(x/10)$ \square

Ejercicio 2


$$P(X \in A) = \int_A f_X(x) dx$$

$$f_{Y|X=x} = \frac{f_{X,Y}(x,y)}{f_X(x)}$$

$$P(Y=2|X=2) = 1$$

$$\cancel{P(Y=2, X=2)} = \frac{P(Y=2, X=2)}{P(X=2)} \rightarrow$$

Sean X, Y dos v.a. conjuntamente uniformes en el triángulo de vértices $(0,0)$, $(2,2)$, $(0,2)$. Hallar la función de densidad de $Y|X=x$.



1) para encontrar la densidad calculamos:

$$f_{X,Y}(x,y) = \frac{1}{2} \mathbb{1}_{\{x,y\} \in \triangle}$$

$$f_X(x) = \int_x^2 \frac{1}{2} \mathbb{1}_{\{0 \leq x \leq y \leq 2\}} dy = \frac{1}{2} (2-x) \mathbb{1}_{\{0 \leq x \leq 2\}}$$

$$f_{Y|X=x}(y) = \frac{\frac{1}{2} \mathbb{1}_{\{0 \leq x \leq y \leq 2\}}}{\frac{1}{2} (2-x) \mathbb{1}_{\{0 \leq x \leq 2\}}} = \frac{1}{2-x} \mathbb{1}_{\{x \leq y \leq 2\}}$$

$$Y|X=x \sim \mathcal{U}(x, 2)$$

Ejercicio 3

$$X \sim E(\lambda) \Rightarrow f_X(x) = \lambda e^{-\lambda x} \quad \text{si } x > 0$$

* Tarea: resolviendo integrando y encontrando la marginal $f_Y(y)$.

Sean X, Y dos v.a. con función de densidad conjunta

$$f_{X,Y}(x,y) = \frac{e^{-x/2y}}{4y} \mathbf{1}\{0 < x, 1 < y < 3\}$$

$\underbrace{\mathbf{1}\{0 < x\} \mathbf{1}\{1 < y < 3\}}$
 $\underbrace{\hspace{10em}}$

Hallar la función de densidad de $X|Y=y$

$$f_{X,Y}(x,y) = f_{X|Y=y} \cdot f_Y(y)$$


solo depende de y

$$= \frac{e^{-x/2y}}{2y} \mathbf{1}\{x > 0\} \cdot \frac{1}{2} \mathbf{1}\{1 < y < 3\}$$

$\underbrace{\hspace{10em}}$
 $\underbrace{\hspace{10em}}$

$X|Y=y \sim E(1/2y) \checkmark$ ← integrar $1/y$ es no negativo

Mezcla de v.a.



Sea M una v.a. discreta a valores $1, \dots, n$, con función de probabilidad $p_M(m)$, y sea X una v.a. tal que se conocen las distribuciones $X|M = m$, $m = 1, 2, \dots, n$. Luego, la distribución de X resulta

$$\underline{\underline{F_X(x) = \sum_{m=1}^n F_{X|M=m}(x) p_M(m)}}$$

$$\begin{aligned} P(x, m) &= P(x|m) P_m \\ \underbrace{m \text{ son disjuntos}}_{\text{Prob. total}} \end{aligned}$$

Obs:

Si X es **v.a.d**: $p_X(x) = \sum_{m=1}^n \underline{\underline{p_{X|M=m}(x) p_M(m)}}$

Si X es **v.a.c**: $\underline{\underline{f_X(x) = \sum_{m=1}^n f_{X|M=m}(x) p_M(m)}}$

Bayes para mezclas

Sea M una v.a. discreta a valores $1, \dots, n$, con función de probabilidad $p_M(m)$, y sea X una v.a. continua tal que se conocen las distribuciones $f_{X|M=m}(x)$, $m = 1, 2, \dots, n$, la función de probabilidad de M dado que $X = x$ será:

$$p_{M|X=x}(m) = \frac{f_{X|M=m}(x)p_M(m)}{\sum_{m=1}^n f_{X|M=m}(x)p_M(m)}$$

Handwritten annotations:

- Blue bracket above $f_{X|M=m}(x)p_M(m)$ in numerator: "tengo"
- Red bracket below $\sum_{m=1}^n f_{X|M=m}(x)p_M(m)$: "f x" with a circled 1
- Arrow pointing to the denominator: "me da el problema"

Ejercicio 4

Para ir al trabajo Juan puede tomar el subte, o el tren, eligiendo viajar en tren el 60% de las veces. Si viaja en subte, el tiempo de viaje (en horas) es una v.a. con distribución $U(0.75, 1)$, mientras que si viaja en tren distribuye de manera uniforme en el intervalo $(0.8, 1.25)$.

1. Calcular la función de densidad del tiempo viaje.
2. Calcular la probabilidad de que haya viajado en subte si un cierto día tardó exactamente 0.9 hs.

Para ir al trabajo Juan puede tomar el subte, o el tren, eligiendo viajar en tren el 60% de las veces. Si viaja en subte, el tiempo de viaje (en horas) es una v.a. con distribución $U(0.75, 1)$, mientras que si viaja en tren distribuye de manera uniforme en el intervalo $(0.8, 1.25)$.

1. Calcular la función de densidad del tiempo viaje. T ✓
2. Calcular la probabilidad de que haya viajado en subte si un cierto día tardó exactamente 0.9 hs.

$$P(M=1 | T=0.9)$$

$$M = \begin{cases} 0 & \text{Juan toma el tren} \\ 1 & \text{Juan toma el subte} \end{cases}$$

$$P(M=0) = 0.6 \quad P(M=1) = 0.4$$


T : "tiempo de viaje"

$$T | M=0 \sim U(0.8; 1.25)$$

$$T | M=1 \sim U(0.75; 1)$$

$$f_T(t) = P_{T|M=0} \cdot P(M=0) + P_{T|M=1} \cdot P(M=1)$$

$$= \underbrace{\frac{0.6}{0.45}}_{\sim 1.33} \cdot \mathbb{I}_{\{0.8 \leq t \leq 1.25\}} + \underbrace{\frac{0.4}{0.25}}_{\sim 1.6} \cdot \mathbb{I}_{\{0.75 \leq t \leq 1\}}$$



$$T/\mu = 1 \sim \mathcal{U}(0, 75; 1)$$

$$f_{T|\mu=1}$$

$$P(\mu=1/T=0,9) = \frac{f_{T|\mu=1}(0,9) \cdot P(\mu=1)}{f_T(0,9)}$$

$$= \frac{\frac{0,4}{0,25}}{\frac{0,6}{0,45} + \frac{0,4}{0,25}} \approx \frac{1,6}{2,93} \sim 0,54$$

Normal multivariada: dist. condicionales

$\text{Sea } \mathbf{X} = [X_1, X_2]^T \sim \mathcal{N}(\boldsymbol{\mu}, \Sigma)$

medios \downarrow *matriz de covarianza* \downarrow *independientes*
 $\Rightarrow X_i \sim \mathcal{N}(\mu_i, \Sigma_{ii})$

condicionales $\left\{ \right.$

$$X_1 | X_2 = x_2 \sim \mathcal{N} \left(\underbrace{\mu_1 + \frac{\text{cov}(X_1, X_2)}{\sigma_2^2} (x_2 - \mu_2)}_{\substack{\text{coef.} \\ E[X_1 | X_2 = x_2]}}, \left(1 - \frac{\text{cov}(X_1, X_2)^2}{\sigma_1^2 \sigma_2^2}\right) \sigma_1^2 \right)$$

$E[X_1 | X_2 = x_2]$ es lineal en x_2 .

$$X_2 | X_1 = x_1 \sim \mathcal{N} \left(\mu_2 + \frac{\text{cov}(X_1, X_2)}{\sigma_1^2} (x_1 - \mu_1), \left(1 - \frac{\text{cov}(X_1, X_2)^2}{\sigma_1^2 \sigma_2^2}\right) \sigma_2^2 \right)$$

Esperanza condicional

Motivación

En dónde podemos aplicar la esperanza condicional?

- ◉ Regresión: se usa para predecir el valor de la variable objetivo, dado un conjunto de variables condicionales (observaciones)
- ◉ Reinforcement learning: usamos la esperanza condicional para estimar la recompensa esperada al tomar una acción en un estado dado. Esta estimación se usa para guiar al agente en la toma de decisiones
- ◉ Detección de anomalías: se usa para predecir el valor esperado de una variable basado en sus valores previos (y otras variables). Si el valor actual se desvía mucho, puede indicar una anomalía
- ◉ Sistemas de recomendación: se usa para predecir la preferencia del usuario por cierto contenido o servicio, por ejemplo en técnicas de collaborative filtering models

Función de regresión

Def: Sean X, Y dos v.a. **discretas**, se llama **función de regresión** a

$$\varphi(x) = \underline{\underline{\mathbb{E}[Y|X=x]}} = \underline{\sum_{y \in R_Y} y p_{Y|X=x}(y)}, \quad \forall x \in R_X$$

prob. condicional de $Y|X$

Def: Sean X, Y dos v.a. **continuas**, se llama **función de regresión** a

$$\varphi(x) = \underline{\underline{\mathbb{E}[Y|X=x]}} = \int_{y \in R_Y} y \underline{f_{Y|X=x}(y)}, \quad \forall x \in R_X$$

densidad condicional de $Y|X$

Observar que es función de x

Ejercicio 5

Continuando con los ejercicios anteriores calcular la función de regresión de $X|Y=y$ o $Y|X=x$ según corresponda:

1. La probabilidad de acertar a un blanco es $\frac{1}{5}$. Se realizan 10 tiros independientes y se cuenta la cantidad de aciertos. Sean X la cantidad de aciertos en los 10 tiros, e Y la cantidad de aciertos en el primer tiro. Hallar la distribución de $X|Y=y$ y $Y|X=x$.

$$Y|X=x \sim \text{Ber}\left(\frac{x}{10}\right)$$

$$E[Y|X=x] = \frac{x}{10}$$

2. Sean X, Y dos v.a. conjuntamente uniformes en el triángulo de vértices $(0,0)$, $(2,2)$, $(0,2)$. Hallar la función de densidad de $Y|X=x$.

$$Y|X=x \sim \mathcal{U}(x, 2)$$

$$E[Y|X=x] = \frac{2+x}{2} = 1 + \frac{Y}{2}$$


3. Sean X, Y dos v.a. con función de densidad conjunta

$$f_{X,Y}(x,y) = \frac{e^{-x/2y}}{4y} \mathbf{1}\{0 < x, 1 < y < 3\}$$

$$X|Y=y \sim \mathcal{E}(1/2y)$$

$$E[X|Y=y] = 2y$$

Hallar la función de densidad de $X|Y=y$




Esperanza condicional

"Espacio de Hilbert"

$$\langle X, Y \rangle = E[XY]$$

XY v.e. con $Var(X) < \infty$

$$\|X\|^2 = \langle X, X \rangle = E[X^2] = Var(X) + E[X]^2$$



Def: La variable aleatoria **esperanza condicional** de Y dada X se define como

$$E[Y|X] = \varphi(X).$$

$$\langle (Y - E[Y|X]), t(X) \rangle$$

Además $\varphi(X)$ satisface que $E[(Y - \varphi(X)) t(X)] = 0$ para toda función medible $t : R_X \rightarrow \mathbb{R}$, tal que $E[t(X)] < \infty$.

$E[Y|X]$ es el **mejor predictor** de Y basado en X (i.e. es la **proyección ortogonal** de Y en el espacio de funciones de X)

Propiedades

$$f_Y = f_{Y|X} \cdot f_X$$

1. $\mathbb{E}[Y] = \mathbb{E}[\mathbb{E}[Y|X]]$ \rightarrow empezamos iterando

2. $\mathbb{E}[r(X)s(Y)|X] = r(X)\mathbb{E}[s(Y)|X]$, para r, s tal que $r(X)s(X)$, $r(X)$ y $s(Y)$ tienen esperanza finita

3. $\mathbb{E}[aY_1 + bY_2|X] = a\mathbb{E}[Y_1|X] + b\mathbb{E}[Y_2|X]$ *lineal*

4. $\mathbb{E}[Y|X] = \mathbb{E}[Y]$ si X y Y son independientes $f_{Y|X} = f_Y$