

# Probabilidad y estadística

## Clase 2

# Transformaciones de variables

# Función de variable aleatoria

# Método de la transformada inversa

El objetivo es poder generar una variable aleatoria con una cierta distribución deseada a partir de una que conozco.

Es decir, quiero construir una variable aleatoria cuya función de distribución sea una  $F$  dada.

# Método de la transformada inversa

Sea  $F : \mathbb{R} \rightarrow [0, 1]$  una función de distribución, existe una variable aleatoria

$$X / \boxed{F(x)} = \mathbb{P}(X \leq x)$$

Definimos la inversa generalizada como:



$$\{ F_X^{-1}(u) = \min\{x \in \mathbb{R} : \overbrace{F_X(x)}^{\text{continuo}} \geq u\}, u \in (0, 1) \} = \{x : F_X(x) = u\} = \overline{F_X^{-1}}(u)$$

**Teorema:** Si  $\boxed{F}$  es una función que cumple que

- Es no decreciente ✓
- $\lim_{x \rightarrow -\infty} F(x) = 0$  ✓ y  $\lim_{x \rightarrow \infty} F(x) = 1$  ✓
- Es continua a derecha ✓

$\Rightarrow F$  es una fun de distribución

Entonces, si defino  $\boxed{X = F^{-1}(U)}$  con  $U \sim \mathcal{U}(0, 1)$   $X$  es una v.a. con función de distribución  $\boxed{F}$

genero  
muestras  
de  $X$   
un fun  
de distr  
 $F$

# Ejercicio 1

$$X \in \{1, \dots, 6\} \text{ y } P(X=i) = \frac{1}{6} \quad i=1, \dots, 6$$

Sea  $X$  el resultado de arrojar un dado equilibrado. A partir de 1000 realizaciones de una v.a. uniforme en el intervalo  $(0,1)$ , simular 1000 realizaciones de  $X$ .

$$\begin{array}{l} U \\ \downarrow \\ F_X^{-1}(u) = \end{array} \left\{ \begin{array}{ll} 1 & \text{si } 0 \leq u < 1/6 \\ 2 & \text{si } 1/6 \leq u < 2/6 \\ 3 & \dots \\ 6 & \text{si } 5/6 \leq u < 1 \end{array} \right. \rightarrow X$$

# Ejercicio 2

$X$ : "tiempo entre llamadas"

$$f_X(x) = \frac{1}{5} e^{-1/5 x} \mathbb{1}_{\{x \geq 0\}} \Rightarrow F_X(u) = \int_{-\infty}^u f_X(x) dx = \int_0^u \frac{1}{5} e^{-1/5 x} dx = -e^{-1/5 x} \Big|_0^u = (1 - e^{-1/5 u}) \mathbb{1}_{\{u \geq 0\}}$$
$$F_X(x) = y \Rightarrow 1 - e^{-u/5} = y \Rightarrow 1 - y = e^{-u/5} \Rightarrow u = -5 \log(1 - y)$$

El tiempo (en minutos) entre llamadas a un call center tiene una distribución exponencial de parámetro  $1/5$ .

A partir de 1000 observaciones de una v.a. uniforme en el intervalo  $(0,1)$ , simular 1000 valores de tiempos entre llamadas.

$$F_X^{-1}(y) = -5 \log(1 - y)$$

$\swarrow$  uniforme  $(0,1)$

$\swarrow$   $X / F_X(u)$  se es su fun. de distrib. i.e.  $X \sim \mathcal{E}(1/5)$

# Función de variable aleatoria



# Motivación

$$Y = g(X)$$

↑  
 $\mathbb{R} \rightarrow \mathbb{R}$

En este caso, lo que conocemos es la relación entre variables aleatorias (transformación), pero sólo conocemos la distribución de una ellas.

**Usos:** en ML, se suele usar la transformación de variables para mejorar los resultados de ajustes y predicciones.

Algunas transformaciones más comunes son

- Log
- Exp
- Sqrt
- Inversa
- Binning

# Usos en ML y DS

- Ingeniería de features: binning, log, exp, etc.
- Normalización
- Aumentación de datos. Ej: en imágenes se aplican tx como rotaciones, traslaciones, etc.
- Interpretación del modelo. Por ej. en RL cuando incluimos  $X_2$ ,  $X_3$ , etc. como regresores.

$$\hat{y} = \alpha x_1 + \beta x_2$$

# Definición

Sea  $X$  una v.a. con función de distribución  $F_X(x)$ , y sea  $Y = g(X)$  una función de la variable aleatoria  $X$ . El objetivo es hallar la función de  $Y$ .

Esto puede hacerse considerando que  $F_Y(y) = P(Y \leq y) = P(g(X) \leq y)$  y desarrollando la probabilidad en términos de la v.a.  $X$ .

A este camino se lo llama **método de eventos equivalentes**.

# Ejercicio 3

me hace integral L.

$$f_X(x) = \frac{1}{2} \mathbb{1}_{\{-1 \leq x \leq 1\}}$$

$$1 = \int_{-\infty}^{\infty} f_X(x) dx = \int_{-1}^1 \frac{1}{2} \mathbb{1}_{\{-1 \leq x \leq 1\}} dx = \int_{-1}^1 \frac{1}{2} dx = \frac{1}{2} \cdot 2$$

Sea  $X \sim U(-1,1)$ , y sea  $Y = X^2$ . Hallar la función de densidad de  $Y$


$$F_Y(y) = P(Y \leq y) = P(X^2 \leq y) = P(|X| \leq \sqrt{y}) = P(-\sqrt{y} \leq X \leq \sqrt{y})$$

$$= \int_{-\sqrt{y}}^{\sqrt{y}} \frac{1}{2} \mathbb{1}_{\{-1 \leq x \leq 1\}} dx = \begin{cases} \int_{-\sqrt{y}}^{\sqrt{y}} \frac{1}{2} dx = \frac{2\sqrt{y}}{2} = \sqrt{y} & 0 \leq y < 1 \\ 0 & y \leq 0 \\ 1 & y \geq 1 \end{cases}$$

$$0 \leq y < 1 \rightarrow \mathbb{1}_{\{-1 \leq x \leq 1\}} = 1$$

$$y \leq 0 \leftarrow (i)$$

$$y \geq 1 \leftarrow (iii)$$



$$f_Y(y) = \frac{d}{dy} F_Y(y) = \frac{1}{2\sqrt{y}}$$

$$= P(Y \leq 1)$$

$$\mathbb{1}_{\{0 < y < 1\}}$$

# Ejercicio 4

En un equipo de fútbol, Juan y Esteban son los encargados de patear penales. En un torneo Juan pateó 3 penales, mientras que Esteban pateó 5. Si ambos tienen una probabilidad de 0.4 de acertar cada penal, ¿qué distribución sigue el total de penales acertados?

En un equipo de fútbol, Juan y Esteban son los encargados de patear penales. En un torneo Juan pateó 3 penales, mientras que Esteban pateó 5. Si ambos tienen una probabilidad de 0.4 de acertar cada penal, ¿qué distribución sigue el total de penales acertados?

$X$ : # de penales que acierta Juan  
 $Y$ : " " " Esteban  
 $W$ : " " " Juan o Esteban

$\rightarrow X \sim \text{Bin}(3; 0.4)$   
 $\rightarrow Y \sim \text{Bin}(5; 0.4)$   
 $\rightarrow W = X + Y$

$$P_W(w) = P(W=w), \quad 0 \leq w \leq 8$$

$$= \sum_{i=0}^w P(X=i; Y=w-i)$$

$$= \sum_{i=0}^w P(X=i) \cdot P(Y=w-i)$$

$$= \sum_{i=0}^w \binom{3}{i} 0.4^i 0.6^{3-i} \binom{5}{w-i} 0.4^{w-i} 0.6^{5-w+i}$$

$$= 0.4^w 0.6^{8-w} \sum_{i=0}^w \binom{3}{i} \binom{5}{w-i}$$

$$\rightarrow \binom{8}{w}$$

$$\Rightarrow W \sim \text{Bin}(8; 0.4)$$

$$X = \sum_{i=1}^3 B_i \quad B_i \stackrel{\text{iid}}{\sim} \text{Ber}(0.4)$$

$$Y = \sum_{j=1}^5 B_j \quad B_j \stackrel{\text{iid}}{\sim} \text{Ber}(0.4)$$

$$W = X + Y = \sum_{i=1}^3 B_i + \sum_{j=1}^5 B_j = \sum_{i=1}^8 B_i \Rightarrow W \sim \text{Bin}(8; 0.4)$$

# Ejercicio 5

$$T \sim \mathcal{E}(1000)$$

La cantidad de kilómetros que dura una cámara de bicicleta sigue una distribución exponencial de media 1000. .

Hallar la distribución de la cantidad de kilómetros que se puede usar una bicicleta antes de tener que realizar la primera reparación.

$$Y = \min(T_1, T_2) \quad \text{con} \quad T_1, T_2 \sim \mathcal{E}(1000)$$

$$\begin{aligned} F_Y(y) &= P(Y \leq y) = P(\min(T_1, T_2) \leq y) = 1 - P(\min(T_1, T_2) > y) \\ &= 1 - P(T_1 > y, T_2 > y) = \dots \text{ indep} \end{aligned}$$

# Método de transformaciones

continuas



- Sea  $X$  una v.a.c. con función de densidad  $f_X(x)$ ,
- Sea  $Y=g(X)$ .
- $g(x)$  es una función 1 a 1 (existe  $g^{-1}(y)$ )

$$f_Y(y) = f_X(g^{-1}(y)) \left| \frac{dg^{-1}(y)}{dy} \right|$$

$$\begin{aligned} F_Y(y) &= P(Y \leq y) \\ &= P(g(X) \leq y) \\ &= P(X > g^{-1}(y)) \\ &= 1 - F_X(g^{-1}(y)) \quad \text{g es creciente} \\ &= P(X \leq g^{-1}(y)) \quad \text{g es decreciente} \\ &= F_X(g^{-1}(y)) \end{aligned}$$

$$f_Y(y) = \frac{d}{dy} F_Y(y) = f_X(g^{-1}(y)) \cdot \frac{dg^{-1}(y)}{dy}$$



# Método del Jacobiano

Sean  $X_1$  y  $X_2$  son v.a **continuas** con función de densidad conjunta  $f_{X_1, X_2}(x_1, x_2)$ . Sean también  $h_1, h_2$  dos func. tales que para todo  $(x_1, x_2)$  en el soporte de  $(X_1, X_2)$ ,  $y_1 = h_1(x_1, x_2)$  y  $y_2 = h_2(x_1, x_2)$  son una transformación uno a uno con **inversa**  $x_1 = h_1^{-1}(y_1, y_2)$  y  $x_2 = h_2^{-1}(y_1, y_2)$ . Si las inversas tienen **derivadas parciales continuas** respecto de  $y_1$  e  $y_2$  y jacobiano  $J$ , entonces la densidad conjunta de  $Y_1, Y_2$  será:

$$f_{Y_1, Y_2}^{(y_1, y_2)} = f_{X_1, X_2}(x_1, x_2) \Big|_{h_1^{-1}(y_1, y_2), h_2^{-1}(y_1, y_2)} |J|$$

$$J = \begin{pmatrix} \frac{dh_1^{-1}}{dy_1} & \frac{dh_1^{-1}}{dy_2} \\ \frac{dh_2^{-1}}{dy_1} & \frac{dh_2^{-1}}{dy_2} \end{pmatrix}$$

Otraz form:

$$f_{y_1 y_2}(y_1, y_2) = \frac{f_{x_1 x_2}(x_1, x_2)}{\det(\tilde{J})} \quad \left| \begin{array}{l} x_1 = h_1^{-1}(y_1, y_2) \\ x_2 = h_2^{-1}(y_1, y_2) \end{array} \right.$$

$$\tilde{J} = \begin{bmatrix} \frac{\partial h_1}{\partial x_1} & \frac{\partial h_1}{\partial x_2} \\ \frac{\partial h_2}{\partial x_1} & \frac{\partial h_2}{\partial x_2} \end{bmatrix}$$

# Ejercicio 6

→ indep  $\Rightarrow$  cov = 0

(para la Normal cov = 0  $\Rightarrow$  indep)

$$\begin{matrix} \mu \\ \downarrow \\ \sum \\ \downarrow \\ \Sigma = I \end{matrix}$$

$$\begin{pmatrix} x_1 \\ x_2 \end{pmatrix} \sim N \left( \begin{pmatrix} 0 \\ 0 \end{pmatrix}, \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} \right)$$

matriz de rotación  
 $R$

Sean  $\overbrace{X_1, X_2}^{i.i.d} \sim \mathcal{N}(0, 1)$  y sean  $\begin{pmatrix} U \\ V \end{pmatrix} = \begin{pmatrix} \cos(\theta) & -\sin(\theta) \\ \sin(\theta) & \cos(\theta) \end{pmatrix} \begin{pmatrix} X \\ Y \end{pmatrix}$ . Hallar  $f_{U,V}(u, v)$

$$\begin{pmatrix} x \\ y \end{pmatrix} = \underbrace{\begin{pmatrix} \cos \theta & -\sin \theta \\ \sin \theta & \cos \theta \end{pmatrix}^{-1}}_{R^{-1}} \begin{pmatrix} U \\ V \end{pmatrix} = \underbrace{\begin{pmatrix} \cos \theta & \sin \theta \\ -\sin \theta & \cos \theta \end{pmatrix}}_{R^{-1}} \begin{pmatrix} U \\ V \end{pmatrix}$$

$$J = \begin{pmatrix} \frac{\partial x_1}{\partial u} & \frac{\partial x_1}{\partial v} \\ \frac{\partial x_2}{\partial u} & \frac{\partial x_2}{\partial v} \end{pmatrix} = \begin{pmatrix} \cos \theta & \sin \theta \\ -\sin \theta & \cos \theta \end{pmatrix} \Rightarrow |J| = \cos^2 \theta + \sin^2 \theta = 1$$

$$f_{U,V}(u, v) = f_{X,Y}(x, y) \Big|_{\begin{pmatrix} x \\ y \end{pmatrix} = R^{-1} \begin{pmatrix} u \\ v \end{pmatrix}} = \frac{1}{2\pi} e^{-\frac{1}{2} \begin{pmatrix} x \\ y \end{pmatrix}^T I \begin{pmatrix} x \\ y \end{pmatrix}} \Big|_{R^{-1} \begin{pmatrix} u \\ v \end{pmatrix}} = \frac{1}{2\pi} e^{-\frac{1}{2} \begin{pmatrix} u \\ v \end{pmatrix}^T (R^{-1})^T I R^{-1} \begin{pmatrix} u \\ v \end{pmatrix}}$$



$$f_{u,v}(u,v) = \frac{1}{2\pi} e^{-\frac{(u,v)^T \overset{\sim=R}{(R^{-1})^T} I R^{-1} (u,v)}{2}}$$

$R$  is orthogonal  
 $\Rightarrow R^T = R^{-1}$

$$= \frac{1}{2\pi} e^{-\frac{(u,v)^T R R^{-1} (u,v)}{2}}$$

$$= \frac{1}{2\pi} e^{-\frac{(u,v)^T I (u,v)}{2}}$$

$$\Rightarrow \begin{pmatrix} u \\ v \end{pmatrix} \sim \mathcal{N}\left(\begin{pmatrix} 0 \\ 0 \end{pmatrix}, I\right)$$



$$\sigma_2^2 > \sigma_1^2$$

# Ejercicio 7

Sean  $X_1, X_2 \stackrel{i.i.d}{\sim} \mathcal{E}(\lambda)$  y sean  $U = X_1 + X_2$  y  $V = \frac{X_1}{X_1 + X_2}$ . Hallar  $f_{U,V}(u, v)$  ¿Qué puede decir al respecto?

Sean  $X_1, X_2 \stackrel{i.i.d}{\sim} \mathcal{E}(\lambda)$  y sean  $U = X_1 + X_2$  y  $V = \frac{X_1}{X_1 + X_2}$ . Hallar  $f_{U,V}(u,v)$ . ¿Qué puede decir al respecto?

$\Rightarrow U \sim \Gamma(2, \lambda)$  y  $V \sim \text{Unif}(0,1)$   
y son indep.

$$h_1(x_1, x_2) = x_1 + x_2 = u \quad \Rightarrow \quad x_2 = u - x_1 = u(1-v) = h_1^{-1}(u, v)$$

$$h_2(x_1, x_2) = \frac{x_1}{x_1 + x_2} = v \quad \Rightarrow \quad x_1 = uv = h_2^{-1}(u, v)$$

$x_1 + x_2 = u$

$$J = \begin{pmatrix} 1-v & -u \\ v & u \end{pmatrix} \quad |\det J| = |u(1-v) + uv| = |u| = u$$

$$f_{UV}(u, v) = f_{X_1, X_2}(x_1, x_2) \bigg|_{\substack{x_1 = uv \\ x_2 = u(1-v)}} |\det J|$$

$u$  es una  $2^{\text{a}}$  u.z. position.  
 $\Rightarrow u \geq 0$

$$= \lambda^2 e^{-\lambda x_1} \mathbb{1}_{\{x_1 \geq 0\}} \cdot \lambda e^{-\lambda x_2} \mathbb{1}_{\{x_2 \geq 0\}} \bigg|_{\substack{x_1 = uv \\ x_2 = u(1-v)}} u$$

$$= \lambda^2 e^{-\lambda (x_1 + x_2)} u \mathbb{1}_{\{uv \geq 0\}} \mathbb{1}_{\{u(1-v) \geq 0\}}$$

$$U \sim \Gamma(2, \lambda) = \boxed{\lambda^2 e^{-\lambda u} u^{1 \nearrow} \mathbb{1}_{\{u \geq 0\}}} \times \boxed{\mathbb{1}_{\{0 < v < 1\}}} \Rightarrow V \sim \text{Unif}(0,1)$$

$\lambda^2 / \Gamma(2) \text{ pero } \Gamma(2) = 1! = 1$







# Método del Jacobiano

## Observación:

Si solamente me interesa una única función de las variables, por ejemplo  $U_1 = h_1(Y_1, Y_2)$  puedo “inventarme” una  $U_2 = h_2(Y_1, Y_2)$  y aplicar el método del Jacobiano para encontrar la función de densidad conjunta de ambas variables.

Finalmente, calculo la densidad marginal de la v.a. deseada  $U_1$ .

# Método del jacobiano generalizado (BONUS)

Si  $\underline{X}$  un vector aleatorio e  $\underline{Y} = g(\underline{X})$  con  $g$  tal que  $g|_{A_i} = g_i : A_i \rightarrow B$  biyectiva, continua, con derivada continua, donde  $A_1, \dots, A_k$  es una partición del  $\text{supp}(X)$ , entonces

$$f_{\underline{Y}}(\underline{y}) = \sum_{i=1}^k \frac{f_{\underline{X}}(\underline{x}) \mathbf{1}_{\{\underline{x} \in A_i\}}}{|J_{g_i}(\underline{x})|} | \underline{x} = g_i^{-1}(\underline{y})$$


# Ejercicio 2

Sea  $X \sim U(-1,1)$  e  $Y=X^2$ . Hallar por el método del Jacobiano generalizado la función de densidad de  $Y$ .

# Observación: Suma de v.a.

Sean  $X, Y$  dos v.a. con función de densidad  $f_X(x)$  y  $f_Y(y)$ , la variable  $W = X + Y$  tiene densidad:

$$f_W(w) = f_X(x) * f_Y(y)$$



Donde  $*$  representa la **función convolución** definida por:

$$(f * g)(t) = \int_{-\infty}^{\infty} f(\tau)g(t - \tau)d\tau$$

$f, g$  continuas

$$(f * g)(n) = \sum_{k=-\infty}^{\infty} f(k)g(n - k)$$

$f, g$  discretas

# Función generadora de momentos

Habíamos definido a la función **generadora de momentos** de  $X$  como

$$M_X = \mathbb{E}[e^{tX}]$$

**Teorema:** Sean  $M_X$  y  $M_Y$  dos funciones generadoras de momentos de las v.a.  $X$  e  $Y$ , respectivamente. Si

$$M_X(t) = M_Y(t)$$

Para todo  $t$ , entonces  $X$  e  $Y$  tienen la misma distribución.

# V.A Gaussianas: Proyección

Sea  $\underline{X} \sim \mathcal{N}(\underline{\mu}, \Sigma)$  de dimensión  $n$ . Y sea  $w \in \mathbb{R}^n$ .  
Definamos  $Z = w^T \underline{X}$  la proyección de  $\underline{X}$  en  $w$

$$Z \sim \mathcal{N}(w^T \underline{\mu}, w^T \Sigma w)$$