

Probabilidad y Estadística

Clase 3

Bayes para mezclas

Sea M una v.a. discreta a valores $1, \dots, n$, con función de probabilidad $p_M(m)$, y sea X una v.a. continua tal que se conocen las distribuciones $f_{X|M=m}(x)$, $m = 1, 2, \dots, n$, la función de probabilidad de M dado que $X = x$ será:

$$p_{M|X=x}(m) = \frac{f_{X|M=m}(x)p_M(m)}{\sum_{m=1}^n f_{X|M=m}(x)p_M(m)}$$



$$f_x(x)$$

Función generadora de momentos

Definimos a la función generadora de momentos de X como

$$\frac{d m(t)}{dt} = \frac{d E(e^{tX})}{dt} = E\left(\frac{d e^{tX}}{dt}\right) M_X = \mathbb{E}[e^{tX}] = m(t)$$

Teorema: Sean M_X y M_Y dos funciones generadoras de momentos de las v.a. X e Y, respectivamente. Si

$$\longrightarrow M_X(t) = M_Y(t)$$

Para todo t, entonces X e Y tienen la misma distribución.

$$E(X e^{tx}) = \psi(t) \quad \psi(0) = E(X)$$


V.A Gaussianas: Proyección

Sea $\underline{X} \sim \mathcal{N}(\underline{\mu}, \Sigma)$ de dimensión n. Y sea $w \in \mathbb{R}^n$.

Definamos $Z = w^T \underline{X}$ la proyección de \underline{X} en w

$$\underline{X} \sim \mathcal{N}(\underline{\mu}, \Sigma)$$

$$X \in \mathbb{R}^2$$



$$\underline{\mu} = \begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix}$$


$$\Sigma = \begin{bmatrix} \sigma_1^2 & \text{Cov} X_1 X_2 \\ \text{Cov} X_2 X_1 & \sigma_2^2 \end{bmatrix}$$

Normal multivariada: dist. condicionales

Sea $\mathbf{X} = [X_1, X_2]^T \sim \mathcal{N}(\boldsymbol{\mu}, \Sigma)$

$$X_1 | X_2 = x_2 \sim \mathcal{N} \left(\mu_1 + \frac{\text{cov}(X_1, X_2)}{\sigma_2^2} (x_2 - \mu_2), \left(1 - \frac{\text{cov}(X_1, X_2)^2}{\sigma_1^2 \sigma_2^2}\right) \sigma_1^2 \right)$$

$$X_2 | X_1 = x_1 \sim \mathcal{N} \left(\mu_2 + \frac{\text{cov}(X_1, X_2)}{\sigma_1^2} (x_1 - \mu_1), \left(1 - \frac{\text{cov}(X_1, X_2)^2}{\sigma_1^2 \sigma_2^2}\right) \sigma_2^2 \right)$$



$$X_2 | X_1 = x_1$$

Esperanza condicional

Función de regresión

Def: Sean X, Y dos v.a. **discretas**, se llama función de regresión a

$$\varphi(x) = \mathbb{E}[Y|X=x] = \sum_{y \in R_y} y \underbrace{p_{Y|X=x}(y)}, \quad \forall x \in R_X$$

Def: Sean X, Y dos v.a. **continuas**, se llama función de regresión a

$$\varphi(x) = \mathbb{E}[Y|X=x] = \int_{y \in R_y} y \underbrace{f_{Y|X=x}(y)}, \quad \forall x \in R_X$$

Observar que es función de x

Ejercicio 1

Siguiendo con los ejercicios de la clase pasada calcular la función de regresión de $X|Y=y$ o $Y|X=x$ según corresponda



Sean X, Y dos v.a. conjuntamente uniformes en el triángulo de vértices $(0,0)$, $(2,2)$, $(0,2)$. Hallar la función de densidad de $Y|X=x$.

Sean X, Y dos v.a. con función de densidad conjunta




$$f_{X,Y}(x,y) = \frac{e^{-x/2y}}{4y} \mathbf{1}\{0 < x, 1 < y < 3\}$$

Hallar la función de densidad de $X|Y=y$

Esperanza condicional

Def: La variable aleatoria **esperanza condicional de Y dada X** se define como


$$\mathbb{E}[Y|X] = \varphi(X).$$



Además $\varphi(X)$ satisface que $\mathbb{E}[(Y - \varphi(X)) t(X)] = 0$ para toda función medible $t : R_X \rightarrow \mathbb{R}$, tal que $\mathbb{E}[t(X)] < \infty$.

¿A qué nos recuerda esto?

$\mathbb{E}[Y|X]$ es el **mejor predictor** de Y basado en X (i.e. es la **proyección ortogonal** de Y en el espacio de funciones de X)



Propiedades

1. $\mathbb{E}[Y] = \underbrace{\mathbb{E}[\mathbb{E}[Y|X]]}$
2. $\mathbb{E}[r(X)s(Y)|X] = r(X)\mathbb{E}[s(Y)|X]$, para r, s tal que $r(X)s(X)$,
 $r(X)$ y $s(Y)$ tienen esperanza finita
3. $\mathbb{E}[aY_1 + bY_2|X] = a\mathbb{E}[Y_1|X] + b\mathbb{E}[Y_2|X]$
4. $\mathbb{E}[Y|X] = \mathbb{E}[Y]$ si X y Y son independientes

Ejercicio 2

- 1. Siguiendo con los ejemplos, calcular la esperanza condicional de $X|Y$ o $Y|X$ según corresponda.
- 2. Calcular $E(X)$ para el ultimo ejemplo, usando propiedades de la esperanza.

$$\begin{aligned} E[X] &= E[\underbrace{E[X|Y]}_{= 2Y}] = E[2Y] \\ &= 2E[Y] = 2 \cdot 2 = 4 \end{aligned}$$

Varianza condicional

Def: Dada $\tau(x) = \text{var}(Y|X = x)$, se define la varianza condicional como

$$\mathbb{V}(Y|X) = \tau(X) = \mathbb{E}[Y^2|X] - \mathbb{E}[Y|X]^2$$

Propiedad: (Pitágoras)

$$\text{var}(Y) = \mathbb{E}[\mathbb{V}(Y|X)] + \text{var}(\mathbb{E}[Y|X])$$

Ejercicio 3

1. Siguiendo con los ejemplos del Ej. 1 calcular la varianza condicional de $X|Y$ o $Y|X$ según corresponda
2. Para el último ejemplo, calcular $\text{var}[X]$

Algunos comportamientos límite

LGN + TCL

Ley (débil) de los grandes números

Sucesión de v.a $(X_1, X_2, X_3, \dots, X_n) \stackrel{iid}{\sim} F$ $E(X) = \mu$

Sea $\underline{X} = (X_1, \dots, X_n)$ una muestra aleatoria, con X_i i.i.d con media μ y varianza σ^2 . Para $\epsilon > 0$ se tiene que

$$\rightarrow P\left\{ \left| \frac{\sum_t X_t}{N} - \mu \right| > \epsilon \right\} \rightarrow 0 \text{ cuando } N \rightarrow \infty$$

$$\bar{X}_n = \frac{\sum \tilde{X}_i}{n}$$

Es decir, a medida que crece la cantidad de muestras, el promedio tiende a la media real de la distribución.

$$\bar{X}_n \rightarrow \mu$$

Teorema central del límite

$$(x_1, x_2, \dots, x_n) \stackrel{\text{iid}}{\sim} F$$

$$\sum_{i=1}^n x_i \stackrel{(a)}{\approx} N(n\mu, n\sigma^2) \quad \begin{matrix} n \text{ es} \\ \text{suficiente.} \\ \text{grande.} \end{matrix}$$

$$\frac{\sum_{i=1}^n x_i - n\mu}{\sqrt{n\sigma^2}} \rightarrow N(0, 1)$$

Teorema central del límite

$$(x_1, x_2, \dots, x_n) \stackrel{\text{iid}}{\sim} F$$

$$\bar{x} = \frac{\sum x}{n} \stackrel{(a)}{\sim} N(\mu; \frac{\sigma^2}{n})$$

para n
muy
grandes

$$\frac{\bar{x} - \mu}{\sigma/\sqrt{n}} \rightarrow N(0, 1)$$

Simulación

Estadística

¿Qué es la estadística?

Ahora lo que tenemos son observaciones (realizaciones) de las variables aleatorias.

El objetivo es poder hacer algún tipo de inferencia a partir de los valores observados.

$$(\tilde{x}_1, \tilde{x}_2, \tilde{x}_3, \dots, \tilde{x}_m) \stackrel{iid}{\sim} F$$

nuestra



Muestra aleatoria

Supongamos que tenemos un experimento aleatorio relacionado con una v.a. X . La v.a. X representa un **observable** del experimento aleatorio.

Los valores de X son la **población** de estudio, y el objetivo es saber como se comporta esa población.

Una **muestra aleatoria** de tamaño n , es una sucesión de n v.a **independientes** $\underline{X}_n = (X_1, \dots, X_n)$, tal que $X_i \sim X$

$\rightarrow (x_1, x_2, \dots, x_n) \sim^{\text{def}} F$ PUESTA

DATOS \rightarrow RELACIONES

$(x_1, x_2, x_3, \dots, x_n)$

Estimador

#nuestros #datos

#ESTIMADOR #SISTEMAS

Def: Un **estimador** para una cierta magnitud θ (desconocida) de la distribución de cierta población es una función $\delta(\underline{X})$ de la muestra aleatoria, que devuelve un valor aproximado de θ .

$\theta \rightarrow$ magnitud desconocida

$$\hat{\theta} = \delta(x_1, x_2, \dots, x_n) \rightarrow \text{ESTIMADOR ES UNA VARIABLE ALEATORIA}$$
$$= \delta(\underline{x})$$

(x_1, x_2, \dots, x_n) $x_i = \text{conjunto de datos i-ésimo}$
 $x_i = \text{variable}$

$$\theta = \mu \quad \hat{\theta} = \delta(x_1, x_2, \dots, x_n) = \bar{x} = \frac{\sum x_i}{n} \rightarrow \text{variable aleatoria}$$

Error cuadrático medio

Def: El error cuadrático medio (ECM) como $\underline{\underline{E}}[(\delta(\underline{X}_n) - \theta)^2]$

Def: Un estimador $\delta^*(\underline{X})$ es óptimo si

$ECM(\delta^*(\underline{X})) \leq ECM(\delta(\underline{X}))$ para todo $\delta(\underline{X})$.



Ejercicio 3

Se desea estimar la media de una variable con distribución $N(5,9)$ a partir del promedio de n realizaciones. Hallar el ECM para distintos valores de n .

$$x \sim N(5,9)$$

$$(x_1, x_2, \dots, x_n) \stackrel{iid}{\sim} N(5,9)$$

$$\bar{x} = \frac{\sum x}{n} = \hat{M} \quad E(\bar{x}) = 5$$


$$ECM(\bar{x}) = E[(\bar{x} - 5)^2] = V(\bar{x}) = V\left(\frac{\sum x_i}{n}\right)$$

$$= V\left(\frac{\sum x_i}{n^2}\right) = \frac{\sum V(x_i)}{n^2} = \frac{n \cdot 9}{n^2} = \frac{9}{n} \quad \underbrace{\lim_{n \rightarrow \infty} V(\bar{x}) = 0}$$

ESTIMADOR

INSEGUIDO

CONSISTENTE




$$\lim_{n \rightarrow \infty} \text{ECM}(\hat{\theta}) = 0$$

ESTIMADOR

INSEGUIDO

CONSISTENTE



$$\lim_{n \rightarrow \infty} \text{ECM}(\hat{\theta}) \neq 0$$

Estimadores de mínimos cuadrados

Estimador de mínimos cuadrados

$\hat{Y} \rightarrow$ pronóstico de Y

$\hat{Y} = g(x)$ función de x

$$ECM(\hat{Y}, Y) = E[(\hat{Y} - Y)^2] \quad \begin{matrix} \text{se puede probar} \\ \text{que} \end{matrix}$$

el menor predicción en términos del ECM

es $\underbrace{E[Y|X]}_{\uparrow}$ la respuesta condicional

Estimador de mínimos cuadrados

En otras palabras, queremos $\hat{X} = g^*(Y)$ tal que

$$\mathbb{E}[(X - \hat{X})^2] \leq \mathbb{E}[(X - g(Y))^2] \quad \forall g(Y) \text{ (medible)}.$$

¿Quién era \hat{X} ? $\hat{X} = \mathbb{E}[X|Y]$ ←

Idea de demostración: [Ejercicio]

1. Probar que el mejor estimador constante es $\mathbb{E}[X]$
2. Probar que el mejor estimador condicional es $\mathbb{E}[X|Y = y]$.
3. Dejar que Y tome todos los valores posibles (i.e. reemplazo y por Y), recuperar la esperanza condicional.

Estimador de mínimos cuadrados

Si nos deseanos a $y(x) = ax + b = \hat{y}$

y minimizar $E[(y - (ax + b))^2]$

obtengo $a = \frac{\text{cov}(x, y)}{\text{var}(x)}$

$$b = \frac{\text{cov}(x, y)}{\text{var}(x)} \cdot E(x) + E(y)$$

Ejercicio 4


$$X \sim U(0,1) \quad \underbrace{Y = X^2}$$

Buscamos esperanzas condicionales

$$E[\underbrace{Y|X=x}] = E(X^2) = x^2$$

que pasa si yo no respondo a una pregunta

$$\hat{Y} = (\alpha X + b) =$$



Ejercicio 4

$$\text{C. } \text{cov}x =$$

$$Y = X^2$$

$$E(X) = Y_2$$

$$V(X) = \frac{(1-0)^2}{12} = Y_{12}$$

$$a = \frac{\text{cov}(X, Y)}{V(X)}$$

$$b = \frac{\text{cov}(X, Y)}{V(X)} \cdot E(X) + E(Y)$$

$$E(Y) = \sqrt{E(X^2)} =$$

$$= V(X) + \underbrace{E(X)^2}$$

$$= Y_{12} + Y_1 = Y_3$$

$$\text{cov}(X, Y) = E(X \cdot Y) - E(X) \cdot E(Y) = \underbrace{E(X^3)} - Y_2 \cdot Y_3$$

$$= \int_0^1 x^3 dx - \frac{1}{6} = Y_{12}$$

Regresión lineal

$$(x_1, y_1, \dots, x_n) \quad (y_1, \dots, y_n)$$

Tengo las observaciones (x_1, \dots, x_n) e (y_1, \dots, y_n) , observaciones de dos v.a. X e Y , y queremos hallar la mejor relación lineal $Y = aX + b$.

$$Y = X^T \beta \rightarrow \begin{bmatrix} \beta_0 \\ \beta_1 \end{bmatrix}$$

Definiendo $A = \begin{bmatrix} x_1 & 1 \\ \vdots & \vdots \\ x_n & 1 \end{bmatrix}$, tenemos que

$$[a, b]^T = \underbrace{(A^T A)^{-1} A^T y}_{\hat{\beta}}$$

Nuevamente, la demostración la vimos en AM.