

# Probabilidad y estadística

## Clase 4

# Estadística

# ¿Qué es la estadística?

Ahora lo que tenemos son observaciones (realizaciones) de las variables aleatorias.

El objetivo es poder hacer algún tipo de inferencia a partir de los valores observados.

# Muestra aleatoria


Supongamos que tenemos un experimento aleatorio relacionado con una v.a.  $X$ . La v.a.  $X$  representa un **observable** del experimento aleatorio.

Los valores de  $X$  son la **población** de estudio, y el objetivo es saber como se comporta esa población.

Una **muestra aleatoria** de tamaño  $n$ , es una sucesión de  $n$  v.a **independientes**  $\underline{X}_n = (X_1, \dots, X_n)$ , tal que  $X_i \sim X$

# Estimadores puntuales

# Estimadores puntuales



**Def:** Dada una muestra aleatoria  $\underline{X}_n$ , un estimador  $\hat{\theta}$  de un parámetro  $\theta$  es una función de la muestra aleatoria que provee un valor aproximado del parámetro o característica desconocido.

$$\hat{\theta} = \hat{\theta}(\underline{X}_n) \text{ es una v.a.}$$

# Bondades de los estimadores

$$X \sim F_{\theta}(x)$$

el vln poblacional

$$\int \dots \int_{\mathbb{R}} (\hat{\theta}(x_1, \dots, x_n) - \theta) f(x_1) f(x_2) \dots dx_1 \dots dx_n$$

m.a.  
erum2 v.2  
fijo

- Def:  $\hat{\theta}$  es un estimador **insesgado** para  $\theta$  si  $B := \mathbb{E}[\hat{\theta} - \theta] = 0 \quad \forall \theta$ .

En caso contrario diremos que es **sesgado**. A B se lo conoce como

**sesgo** 1)  $\theta$  fijo, 2)  $x_1, \dots, x_n$  es m.a. con  $x_1 \sim X \sim F_{\theta}(x)$

2) calculo  $\mathbb{E}[\hat{\theta}(x_1, \dots, x_n)] - \theta = B$

- Def:  $\hat{\theta}$  es un estimador **asintóticamente insesgado** para  $\theta$  si

$$\lim_{n \rightarrow \infty} \mathbb{E}[\hat{\theta} - \theta] = 0 \quad \forall \theta$$

$$\hat{\mu} = \frac{1}{n} \sum_{i=1}^n x_i$$

es un estimador de  $\mu$

$$X \sim N(\mu, 1)$$

linealidad


$$B = \mathbb{E}[\hat{\mu}] - \mu = \frac{1}{n} \sum_{i=1}^n \mathbb{E}[x_i] - \mu$$

i.i.d

$$= \frac{1}{n} \sum_{i=1}^n \mu - \mu = 0$$

# Bondades de los estimadores

$\langle x, y \rangle = E[x \cdot y] \rightarrow$  Espacio de Hilbert



**Def:** El error cuadrático medio (ECM) como  $E[(\hat{\theta} - \theta)^2] = \langle \hat{\theta} - \theta, \hat{\theta} - \theta \rangle$

**Obs:** El ECM se puede descomponer como:

Compromiso Sesgo-Varianza

$$ECM = \underbrace{var(\hat{\theta})}_{\text{varianza}} + \underbrace{B(\hat{\theta})^2}_{\text{sesgo}}$$


donde  $var(\hat{\theta}) = E[(\hat{\theta} - E[\hat{\theta}])^2]$  y  $B = E[\hat{\theta} - \theta]$

$$\begin{aligned} & \downarrow \\ & E[(\hat{\theta} - E\hat{\theta}) + (E\hat{\theta} - \theta)]^2 \quad \text{error} \\ & = E[(\hat{\theta} - E\hat{\theta})^2] + 2(E[\hat{\theta} - E\hat{\theta}](E\hat{\theta} - \theta)) \\ & \quad + \underbrace{(E\hat{\theta} - \theta)^2}_B \end{aligned}$$

**Def:** Un estimador  $\theta^*(\underline{X}_n)$  es **óptimo** (en media cuadrática) si  $ECM(\theta^*) \leq ECM(\hat{\theta})$  para todo  $\hat{\theta}(\underline{X}_n)$



# Bondades de los estimadores



**Def:** Dada una sucesión de estimadores  $\hat{\theta}_n$  de  $\theta$ , diremos que  $T = \hat{\theta}$  es (débilmente) **consistente** si  $\forall \varepsilon > 0, \mathbb{P}(|\hat{\theta} - \theta| > \varepsilon) \xrightarrow{n \rightarrow \infty} 0$

**Teorema:** Si  $var(\hat{\theta}) \rightarrow 0$  y  $\mathbb{E}[\hat{\theta}] \rightarrow \theta$ , entonces  $\hat{\theta}$  es consistente.

**Def:** Un estimador es **consistente en media cuadrática** si

$$\lim_{n \rightarrow \infty} ECM(\hat{\theta}_n) = 0, \forall \theta$$

$\underbrace{var(\hat{\theta}) + B^2(\hat{\theta})}_{\downarrow 0 \quad \downarrow 0}$

# Ejercicio 1

Se desea estimar la media de una variable con distribución  $N(\mu, 9)$  a partir del promedio de  $n$  realizaciones. Analizar las bondades de las que goza dicho estimador.

$$X \sim N(\mu, 9)$$

$\bar{X}_n$  es un m.e. de tamaño  $n$  de  $X$  ( $X_1, \dots, X_n$  son iid y  $X_1 \sim X$ )

$$\hat{\mu} = \frac{1}{n} \sum_{i=1}^n X_i, \quad E \hat{\mu} = \mu \Rightarrow \hat{\mu} \text{ es insesgado.}$$

$$\text{var}(\hat{\mu}) = \text{var}\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n^2} \text{var}\left(\sum_{i=1}^n X_i\right) \stackrel{\text{iid}}{=} \frac{1}{n^2} \sum_{i=1}^n \overbrace{\text{var}(X_i)}^9 = \frac{1}{n^2} \cdot n \cdot 9 = \frac{9}{n} \xrightarrow[n \rightarrow \infty]{} 0$$

$\therefore$  el promedio es consistente

# Algunos comportamientos límite

LGN + TCL

# Ley (débil) de los grandes números

Sea  $\underline{X} = (X_1, \dots, X_n)$  una muestra aleatoria, con  $X_i$  i.i.d. con media  $\mu$  y variancia  $\sigma^2$ . Para  $\epsilon > 0$  se tiene que

$$\mathbb{P}(|\overset{\text{promedio}}{\bar{X}}_n - \mu| > \epsilon) \xrightarrow{n \rightarrow \infty} 0$$

Es decir, a medida que crece la cantidad de muestras, el promedio  $\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$  tiende a la media real de la distribución.

# Teorema central del límite

Sea  $\underline{X} = (X_1, \dots, X_n)$  una muestra aleatoria, con  $X_i$  i.i.d. con media  $\mu$  y varianza  $\sigma^2 < \infty$ . Sea  $\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$ , luego

$$\boxed{Z_n} = \frac{\bar{X}_n - \mu}{\sqrt{V(\bar{X}_n)}} = \frac{\sqrt{n}(\bar{X}_n - \mu)}{\sigma} \rightsquigarrow Z$$

*converge en distribución*

con  $Z \sim \mathcal{N}(0, 1)$ , o equivalentemente:

$$\lim_{n \rightarrow \infty} \mathbb{P}(Z_n \leq z) = \Phi(z) = \int_{-\infty}^z \frac{1}{\sqrt{2\pi}} e^{-x^2/2} dx$$

*f. de distr. de la Normal (0,1)*  
*f. de distr. de primer orden estandarizado.*

Es decir,  $\bar{X}_n$  tiene una distribución aproximadamente Normal, con media  $\mu$  y variancia  $\sigma^2/n$ . Para n finito, podemos aproximar

$$\mathbb{P}\left(\frac{\sum_{i=1}^n X_i - n\mu}{\sqrt{n}\sigma} \leq z\right) \approx \Phi(z), \quad \mathbb{P}\left(\sqrt{n} \frac{\bar{X}_n - \mu}{\sigma} \leq z\right) \approx \Phi(z),$$

# Enfoque frecuentista

# Estadístico suficiente $\rightarrow$ Reducción de dimensiones.

**Def:** Dada una muestra aleatoria  $\underline{X}_n$ , un estadístico es cualquier función  $T_n = T(\underline{X}_n)$

• **Def:** Sea una muestra aleatoria  $\underline{X}_n$ , cuya distribución es  $\overbrace{F_\theta(\underline{x})}^{\text{f.p. de parámetro}}$ ,  $\theta \in \Theta$ , se dice que  $T = r(\underline{X}_n)$  es un estadístico suficiente para  $\theta$  si  $F_{\underline{X}|T=t}(\underline{x})$  no depende de  $\theta$ .

• **Teorema de factorización:** Diremos que  $T = r(\underline{X}_n)$  es un est. suficiente para  $\theta$  si existen funciones  $h$  y  $g$  tales que:

$$\boxed{f_\theta(\underline{x}) = \underbrace{g(r(\underline{x}), \theta)}_{\text{función de } \theta} \underbrace{h(\underline{x})}_{\text{función de } \underline{x}}}$$

# Ejercicio 2

1. Hallar un estadístico suficiente para el parámetro de una v.a. con distribución exponencial  $\rightarrow \sum x_i$
2. Hallar un estadístico suficiente para el parámetro de una v.a. con distribución de Bernoulli  $\rightarrow \sum x_i$
3. Hallar un estadístico suficiente para el parámetro de una v.a. con distribución Uniforme en el intervalo  $(0, \theta)$

$$\begin{aligned}
 1) f_{\underline{x}}(\underline{x}) &= \prod_{i=1}^n f_{x_i}(x_i) = \prod_{i=1}^n \lambda e^{-\lambda x_i} \mathbb{1}_{\{x_i \geq 0\}} = \underbrace{\lambda^n e^{-\lambda \sum_{i=1}^n x_i}}_{g(\tau, \theta)} \underbrace{\prod_{i=1}^n \mathbb{1}_{\{x_i \geq 0\}}}_h \\
 2) f_{\underline{x}}(\underline{x}) &= \prod_{i=1}^n p^{x_i} (1-p)^{1-x_i} = \underbrace{p^{\sum_{i=1}^n x_i} (1-p)^{n - \sum_{i=1}^n x_i}}_g
 \end{aligned}$$



$$x_i \sim U(0, \theta)$$

$$f_{\underline{x}}(\underline{x}) = \prod_{i=1}^n \frac{1}{\theta} \mathbb{1}_{\{0 \leq x_i \leq \theta\}} = \frac{1}{\theta^n} \mathbb{1}_{\{\min(x_i) \geq 0\}} \mathbb{1}_{\{\max(x_i) \leq \theta\}}$$

$$g(T, \theta)$$

$$\therefore \boxed{T(\underline{x}_n) = \max(x_i)}$$

# Método de máxima verosimilitud

# Método de Máxima Verosimilitud

**Def:** Diremos que  $\hat{\theta}(\underline{X})$  es un Estimador de Máxima Verosimilitud (MLE) si se cumple que:

$$f(\underline{X}, \hat{\theta}) = \max_{\theta} f_{\theta}(\underline{X})$$

La idea es que si observé una determinada muestra, entonces esta debería tener alta probabilidad de ocurrir, por lo tanto busco el  $\theta$  que maximiza esa probabilidad de ocurrencia

# Método de Máxima Verosimilitud

**Def:** Definimos la función de verosimilitud como

$L(\theta) = f(\underline{x}, \theta)$  (vista como función de  $\theta$ ) luego,

$$\hat{\theta} = \arg \max_{\theta \in \Theta} L(\theta).$$

$\theta \in \Theta \rightarrow$  espacio de parámetros

Si el soporte de  $X$  no depende  $\theta$ ,  $\Theta$  es un conjunto abierto y  $f_{\theta}(x)$  es derivable respecto de  $\theta$ , entonces para hallar el EMV puedo hallar  $\theta$  tal que

$$\left\{ \frac{\partial \ln(L(\theta))}{\partial \theta} = 0 \right\}$$



# Ejercicio 3

La probabilidad de acertar a un blanco es p. Se realizan 10 tiros independientes, en los cuales se observaron 4 aciertos. A partir este valor observado estimar el valor de p por MV.

$$X \sim \text{Ber}(p), \quad 0 \leq p \leq 1.$$

$$\underline{X}_n \text{ con } n=10; T = \sum_{i=1}^n X_i = 4$$

$$\mathcal{L}(p) = \prod_{i=1}^{10} p^{x_i} (1-p)^{1-x_i} = p^{\sum x_i} (1-p)^{10 - \sum x_i} = p^4 (1-p)^6$$

$$\ell(p) := \log \mathcal{L}(p) = 4 \log p + 6 \log (1-p)$$

$$\frac{d}{dp} \ell(p) = \frac{4}{p} - \frac{6}{1-p} = 0 \Rightarrow 4(1-p) = 6p \Rightarrow 4 = 10p \Rightarrow \boxed{\hat{p} = 0,4}$$

# Ejercicio 4

1. Sea  $X \sim U(0, \theta)$ . Hallar el EMV para  $\theta$  basado en una muestra de tamaño  $n$ .  $\Rightarrow \hat{\theta} = \max(x_i)$
2. Si en una muestra de tamaño 3 se observaron los valores (0.756, 1.1, 3.11), hallar el valor estimado de  $\theta$ .  $\Rightarrow \hat{\theta} = 3.11$

$X \sim \text{Unif}(0, \theta)$  y  $\underline{X}_n$  es una m.a. en  $X_1 \sim X$ .

$$\mathcal{L}(\theta) = \prod_{i=1}^n \frac{1}{\theta} \mathbb{1}_{\{0 \leq x_i \leq \theta\}} = \frac{1}{\theta^n} \mathbb{1}_{\{\max(x_i) \geq 0\}} \mathbb{1}_{\{\max(x_i) \leq \theta\}}$$

Diagram illustrating the likelihood function  $\mathcal{L}(\theta)$  for the uniform distribution  $U(0, \theta)$ .

The likelihood function is zero for  $\theta < \max(x_i)$  and increases to its maximum value of  $\frac{1}{\theta^n}$  at  $\theta = \max(x_i)$ .

Handwritten notes and calculations:

- $\mathcal{L}(\theta) = 0$  for  $\theta < \max(x_i)$ .
- $\hat{\theta}'' = \max(x_i)$ .
- $\Rightarrow \mathcal{L}(\hat{\theta}) = \frac{1}{\max(x_i)^n}$ .
- $\mathcal{L}(\hat{\theta}_2) = \frac{1}{\theta_2^n} < \mathcal{L}(\hat{\theta})$ .

# Principio de invariancia

Supongamos que ahora queremos estimar por máxima verosimilitud a  $\lambda = q(\theta)$ .

**Teorema:** Si  $\hat{\theta}$  es MLE de  $\theta$ , entonces  $\hat{\lambda} = q(\hat{\theta})$ . *una función general*

¿Por qué es útil? Por ejemplo, podría querer estimar una probabilidad de la v.a.  $X$ , que en general no puedo porque desconozco el parámetro de la distribución.

$$P(X \in A) = \int_A f_{\theta}(x) dx = q(\theta) \Rightarrow \hat{P}(X \in A) = q(\hat{\theta}) = \int_A \hat{f}_{\hat{\theta}}(x) dx$$

# Ejercicio 5

Siguiendo el ejercicio 3, estimar la probabilidad de que se necesiten al menos 2 tiros para observar el primer acierto.

hoy tenes más que el MLE de  $p$  es  $\hat{p} = 0,4$ .

$$Y \sim \text{Geom}(p)$$

$$P(Y \geq 2) = 1 - P(Y < 2) = 1 - P(Y = 1) = 1 - p$$

Por T. de inversión funcional,


$$\boxed{\hat{P}(Y \geq 2) = 1 - \hat{p} = 1 - 0,4 = \underline{0,6}}$$



# Estimadores de cuadrados mínimos

# Estimador de cuadrados mínimos

$$\langle x, y \rangle = E[XY] \Rightarrow \text{E.H.}$$



Es común querer estimar el valor de una v.a.  $X$  a partir de una medición  $Y$ . Ejemplo:  $Y$  es una versión ruidosa de  $X$ .

Buscamos un estimador  $\hat{X}$  de  $X$  tal que tenga mínimo error cuadrático medio

$$\nearrow \hat{x}(y)$$

$$\text{ECM} = \mathbb{E}[(X - \hat{X})^2 | Y] = \|x - \hat{x}\|^2 | y$$

Observar que se corresponde con la distancia asociada al p.i. canónico para v.a.

# Estimador de mínimos cuadrados

En otras palabras, queremos  $\hat{X} = g^*(Y)$  tal que

$$\mathbb{E}[(X - \hat{X})^2 | Y] \leq \mathbb{E}[(X - g(Y))^2 | Y] \quad \forall g(Y) \text{ (medible)}$$

¿Quién era  $\hat{X}$ ?

$$\hat{X} = \mathbb{E}[X|Y]$$

→ es general

Idea de demostración: [Ejercicio]

$$\Rightarrow g(y) = c$$

1. Probar que el mejor estimador constante es  $\mathbb{E}[X]$
2. Probar que el mejor estimador condicional es  $\mathbb{E}[X|Y = y]$ .
3. Dejar que  $Y$  tome todos los valores posibles (i.e. reemplazo  $y$  por  $Y$ ), recupero la esperanza condicional.

$$1) \frac{d}{dc} E[(x-c)^2] = E[2(x-c)] = 0$$

$$\Rightarrow E[x] = c.$$

$$2) \frac{d}{dg(y)} E[(x - \underbrace{g(y)}_{\text{in cte}})^2 | Y=y] = E[2(x - g(y)) | Y=y] = 0$$

$$\Rightarrow E[x | Y=y] = g(y)$$

$$3) g(y) = E[x | Y].$$

# Mínimos cuadrados: caso lineal

$$\textcircled{x} \quad \hat{x} = \frac{\text{cov}(x,y)}{\text{var}(y)} (y - E[y]) + E[x]$$

↗ necesario  $f_{X|Y} = \frac{f_{XY}}{f_Y}$

A veces obtener  $E[X|Y]$  puede ser muy complicado, entonces nos restringimos a los estimadores lineales.

*Asumir modelo lineal* →

Buscamos  $a, b$  tq  $E[(X - \overbrace{(aY + b)}^{g(y)})^2 | Y]$  sea mínima.



$\textcircled{x}$  Resulta que  $a = \frac{\text{cov}(X,Y)}{\text{var}(Y)}$  y  $b = \frac{\text{cov}(X,Y)}{\text{var}(Y)} E[Y] + E[X]$

**Obs:** Si se asume que  $X$  e  $Y$  son conjuntamente gaussianas, el estimador de mínimos cuadrados (la esperanza condicional) coincide con el estimador de mínimos cuadrados asumiendo un modelo lineal y puede obtenerse a partir del modelo condicional de  $X | Y$

*∴ en el caso gaussiano  $E[X|Y]$  es lineal ⇒ el estimador lineal es óptimo.*

*es lineal*

$$(x_1, x_2) \sim \mathcal{N}\left(\begin{pmatrix} \mu_1 \\ \mu_2 \end{pmatrix}, \begin{pmatrix} \sigma_1^2 & \rho\sigma_1\sigma_2 \\ \rho\sigma_1\sigma_2 & \sigma_2^2 \end{pmatrix}\right) \Rightarrow x_1|x_2 \sim \mathcal{N}\left(\boxed{E[x_1|x_2]}, \text{var}(x_1|x_2)\right)$$

$$E[(X-E_X)(Y-E_Y)] = E[XY] - E_X E_Y - \cancel{E_X E_Y} + \cancel{E_X E_Y}$$

## Ejercicio 6

$$E[(Y-\hat{Y})^2 | X]$$

↓

Sea  $X \sim U(0,1)$  e  $Y=X^2$ . Hallar la mejor aproximación lineal de  $Y$  basada en  $X$ . Comparar con la mejor estimación de  $Y$  basada en  $X$ .

$$\hat{Y} = \frac{\text{cov}(X,Y)}{\text{var}(X)} (X - E[X]) + E[Y]$$

$$\text{cov}(X,Y) = E[(X - E[X])(Y - E[Y])] = E[XY] - E[X]E[Y]$$


$$E[XY] = E_x[E_y[XY|x]] = E[x E[Y|x]] = E[x X^2] = E[X^3] = \int_0^1 x^3 dx = \frac{x^4}{4} \Big|_0^1 = \frac{1}{4}$$

$$E[Y] = E[E[Y|X]] = E[X^2] = \int_0^1 x^2 dx = \frac{x^3}{3} \Big|_0^1 = \frac{1}{3}$$

$$\text{var}(X) = \frac{1}{12}$$

$$\text{cov}(X,Y) = \frac{1}{4} - \frac{1}{2} \cdot \frac{1}{3} = \frac{1}{12}$$

$$\hat{Y} = \frac{1/12}{1/12} \cdot [X - 1/2] + \frac{1}{3} = X - 1/6$$



# Regresión lineal (OLS)

Contamos con  $n$  observaciones conjuntas  $(y_1, x_1), (y_2, x_2), \dots, (y_n, x_n)$   
el modelo de regresión lineal es

$$Y = X\beta + \varepsilon \quad \text{con} \quad \mathbb{E}(\varepsilon_i | X_i) = 0$$

*es lo aleatorio*

donde

$$Y = \begin{pmatrix} Y_1 \\ \vdots \\ Y_n \end{pmatrix}, \quad X = \begin{pmatrix} 1 & X_1 \\ \vdots & \vdots \\ 1 & X_n \end{pmatrix}, \quad \varepsilon = \begin{pmatrix} \varepsilon_1 \\ \vdots \\ \varepsilon_n \end{pmatrix}$$


El estimador de cuadrados mínimos de  $\hat{\beta}$  está dado por

$$\hat{\beta} = (X^T X)^{-1} X^T Y$$

**Obs:** Si se asume que  $\varepsilon_i \sim \mathcal{N}(0, \sigma^2)$  y son i.i.d., este estimador coincide con el estimador de máxima verosimilitud.


$$\rightarrow y|x \sim \mathcal{N}\left(\beta_0 + \begin{pmatrix} \beta_1 \\ \vdots \\ \beta_q \end{pmatrix}^T x, \sigma^2 I\right)$$

$x, \varepsilon$  y  $y$  son multivariados.



$$\min ||y - \hat{y}(x)||_2$$

$$\min \sum_{i=1}^n (y_i - \hat{y}_i)^2$$



# Bibliografía



# Bibliografía

- Notas de estadística. Graciela Boente y Víctor Yohai
- “All of Statistics : A Concise Course in Statistical Inference”, Larry Wasserman, Springer-Verlag New York Inc.
- “Mathematical statistics with applications”, Mendenhall, W., Scheaffer, R. L., & Wackerly, D. D. Boston: Duxbury Press.